Dplyr

Rodrigo Negrete Pérez

July 14, 2022

1. Intro al Tidyverse
2. Lectura de bases de datos
3. Data Pliers
4. Verbos
5. Agrupar datos
6. Otras funciones
7. Merges y cambio de estructura

Section 1

Intro al Tidyverse

Un mundo de datos

- Podemos crear nuestras bases de datos en R
- Sin embargo, su atractivo es manipular datos ya existentes
- Nuestro siguiente paso es descargar bases de datos y prepararlas para el análisis

Paquetes

- Una de las ventajas de R: al ser gratis, hay muchos paquetes con funciones especializadas.
- A menudo, autores publican sus métodos de estimación como paquetes.
- Antes de hacer algo sofisticado, revisa antes si no existe ya un paquete que lo hace.
    - Por ejemplo, muchos loops se pueden hacer con la familia de funciones "apply"

Tidyverse

- Tidyverse es una familia de paquetes estadísticos.
- Vamos a ver “dplyr” -> Data pliers.
- Dedicaremos otras sesión a ““ggplot””.

Instalación de paquetes

- Para todos los paquetes: primero debemos INSTALARLOS UNA SOLA VEZ.
- Encerramos el nombre del paquete entre comillas

```
install.packages('tidyverse')
```

- Antes de usarlos, CARGARLOS CADA VEZ que abramos sesión.

```
library(tidyverse)
```

- Cuando lo cargamos con library() lo escribimos sin comillas.

Section 2

Lectura de bases de datos

Bases de R

- R ya tiene incorporadas algunas bases de datos en el paquete data
- Si ejecutamos **data()** podemos ver la lista de datos

- Están precargados y podemos acceder a ellos solo con su nombre

```
sleep<- sleep
cars<- mtcars
```

Descargar bases de datos

- Lo más común es que trabajemos con bases de datos:
  - Agencias del Estado
  - Investigadores
  - Sector Privado

Directorio

- Antes de leer bases de datos, necesitamos hablar un poco de los directorios.
- Hay muchas maneras para leer bases de datos:
  - Una para cada formato: excel, stata, csv, etc.
- Pero en todas tenemos que especificar dónde está el archivo: el path

Checar directorio

- podemos verificar el directorio con wd()

```
getwd()
```

```
## [1] "C:/Users/rodri/OneDrive - INSTITUTO TECNOLOGICO AUTONO
```

- Por default:
  - R va a buscar archivos en esta carpeta
  - También va a subir archivos a esta carpeta

Ejemplo

- Usaremos la base del INE de la elección presidencial de 2018
- La pueden descargar del Github
  - RodrigoNP/Curso_R
- **Primero debemos descargar el archivo en nuestra carpeta de elección**

Modificando directorio

- Si elegimos modificar el directorio usamos setwd() y ponemos dentro el path de nuestra carpeta.

```
setwd('C:/Users/rodri/OneDrive - INSTITUTO TECNOLOGICO AUTONOM
```

- La última diagonal es la última carpeta en la que está.
- **Observa que es un forward slash**

- Para abrir un archivo excel necesitamos hacer uso de otro paquete: readxl, dentro del tidyverse.
- Una vez modificado el directorio, solo ponemos el nombre y formato del archivo entre como texto (entre comillas)

```
presidencial<- readxl::read_excel('Data/presidencia.xlsx',
                                  skip = 5)
```

- Fíjate en cómo nombro la función y que guardo el df como una variable
  - Podemos citar un paquete con ::
  - Nombramos el paquete :: la función que queremos llamar directamente
- El archivo no puede estar abierto

- Podemos especificar donde empezar a leer los datos con el argumento **skip**
- Podemos especificar cuales son los NA con na=“

Sin modificar directorio

- Si no modificamos el directorio, tenemmos que poner todo el path y el nombre del archivo

```
min<- readxl:: read_excel('C:/Users/rodri/OneDrive - INSTITUTO
```

NA's

- Todas las bases de datos tiene NA.
- Denotan celdas que están vacías, no tienen dato. NO SON 0.
- Podemos especificar qué valores fungen como NA al descargar la base de datos, añadiendo na=c('0', '99', 'etc')

Section 3

Data Pliers

Data Pliers

- El paquete está pensado para preparar los datos
- El objetivo es que una fila sea una observación y una columna sea una variable
- El paquete dplyr tiene una sintaxis sencilla a lo largo de varias funciones

Pipe (pipa)

- El operador más común es el “pipe”, %>%
- Lo podemos escribir fácilmente con Ctrl+ shift+ m
- Quiere decir: *a los datos de la izquierda (pipa) le voy a aplicar el verbo de la derecha*.
- no obstante, podemos omitir la pipa si ponemos la varable del df como primer argumento de la función

Section 4

Verbos

- Los verbos de dpliers también funcionan sin la pipa
- Tienen una sintaxis similar:
  - El primer argumento es un df
  - El segundo argumento describe qué hacer con el df
  - El resultado es un nuevo df
- Los verbos nunca modifican los inputs, así que es necesario crear un nuevo objeto.

Rename()

- Podemos renombrar variables para manipularlas más fácilmente

```
presidencial<-presidencial %>%
  rename(votos=TOTAL_VOTOS_CALCULADOS,
         lista_nominal=LISTA_NOMINAL_CASILLA)
```

- El primer argumento es el nuevo nombre que queremos; el segundo, el nombre original de la variable
- Podemos separar todas las transformaciones con comas

mutate()

- mutate() añade una variable (columna).
- Su atractivo es que podemos utilizar operadores lógicos que relacionen variables dentro de una observación.

- Añadamos el porcentaje de participación

Sin la pipa

- O podríamos poner

```
presidencial<-mutate(presidencial,
                     participacion=votos/
                       lista_nominal)
```

- Esto es válido para todos los verbos del paquete dplier
  - Se puede o no usar la pipa
  - La pipa es útil para concatenar

	CLAVE_CASILLA	participacion	CLAVE_ACTA	ID_ESTADO	N
1	'010000M0100'	0.50	010000M010001	1.00	A
2	'010338B0100'	0.57	010338B010002	1.00	A
3	'010338C0100'	0.57	010338C010002	1.00	A
4	'010338C0200'	0.52	010338C020002	1.00	A
5	'010339B0100'	0.59	010339B010002	1.00	A
6	'010339C0100'	0.58	010339C010002	1.00	A

ifelse()

- Si bien ifelse() no es parte del paquete dpliers, es muy útil para la econometría
- En consonancia con mutate(), podemos hacer dummies muy fácilmente

```
df<-mutate(df,
           dummy=ifelse(condicion a cumplir,
                        que pasa si se cumple,
                        que poner si no))
```

Hagamos una dummy que indique si la casilla es rural

```
presidencial<-presidencial %>%
  mutate(
   rural=ifelse(CASILLA=='Rural',1,0)
  )
```

	CLAVE_CASILLA	rural	CLAVE_ACTA	ID_ESTADO	NOMBRE
1	'010000M0100'		010000M010001	1.00	AGUASC
2	'010338B0100'	1.00	010338B010002	1.00	AGUASC
3	'010338C0100'	1.00	010338C010002	1.00	AGUASC
4	'010338C0200'	1.00	010338C020002	1.00	AGUASC
5	'010339B0100'	1.00	010339B010002	1.00	AGUASC
6	'010339C0100'	1.00	010339C010002	1.00	AGUASC

filter()

- filter() ayuda a quedarnos con observaciones que cumplan con ciertos criterios
- Se quedan las observaciones que produzcan un TRUE dentro de los paréntesis.
- Sirve para crear nuevas bases de datos a partir de las observaciones que nos interesan del df anterior

Operadores lógicos

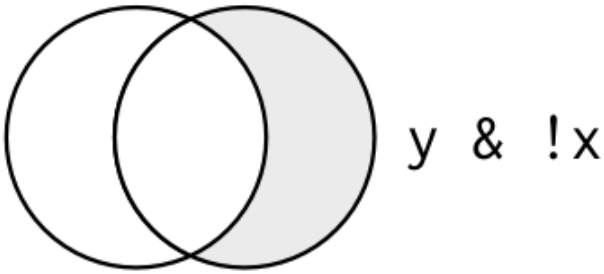

y & !x

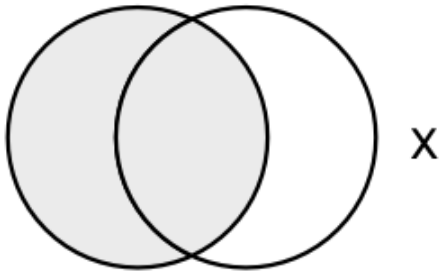

x

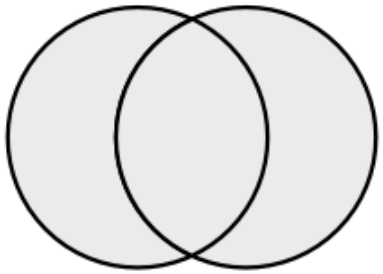

x | y

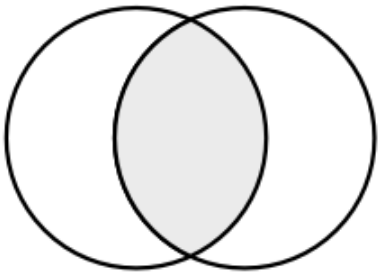

x & y

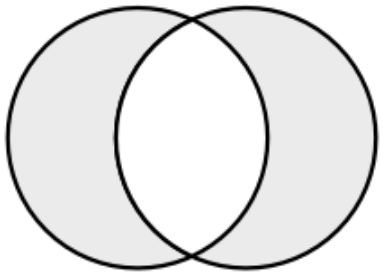

xor(x, y)

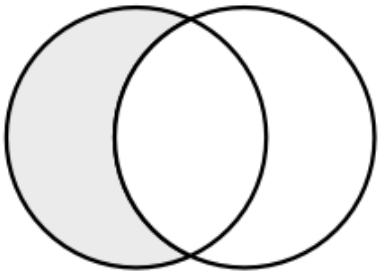

x & !y

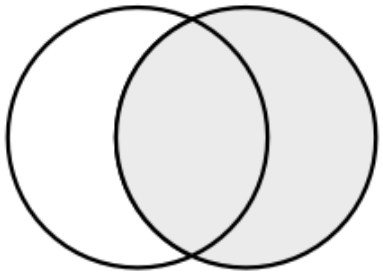

y

Iguales

- Para las comparaciones, se usa ==
- usar = daría un error
- R utitliza un sistema de punto flotante, así que cuidado con sus comparaciones
- Pueden usar **near()** para hacer comparaciones especificando la tolerancia

```
sqrt(2)^2==2
```

```
## [1] FALSE
```

```
near(sqrt(2)^2, 2)
```

```
## [1] TRUE
```

Ley de de Morgan

No a o no b es lo mismo que no a y no b

En lenguaje de R

[!(x & y)= !x | !y]

- Otro operador muy util es %in%

Ejemplo filter()

- Creemos una nueva base de datos en la que solo haya casillas en las que se haya votado por algún independiente

```
independientes<-presidencial %>%
  filter(CAND_IND_01>0 | CAND_IND_02>0)
```

	CAND_IND_01	CAND_IND_02	CLAVE_CASILLA	CLAVE_ACTA
1	0.00	26.00	'010000M0100'	010000M0100
2	0.00	14.00	'010338B0100'	010338B0100
3	0.00	18.00	'010338C0100'	010338C0100
4	0.00	13.00	'010338C0200'	010338C0200
5	0.00	14.00	'010339B0100'	010339B0100
6	0.00	14.00	'010339C0100'	010339C0100

select()

- select() hace lo mismo que filter(), pero con variables (columnas).
- Algunos auxiliares son:
  - starts_with(' ') para variables con un prefijo en común
  - ends_with(' ')
  - contains
  - num_range('x', 1:3) para x1, x2, x3
  - everything() toma el resto del df, muy util para reacomodar

Ejemplo select()

Creemos un df que contenga la clave de la casilla, el estado y solo Morena y sus coaliciones

```
morena<- presidencial %>%
  select(CLAVE_CASILLA, NOMBRE_ESTADO,
         contains('MORENA'))
```

	CLAVE_CASILLA	NOMBRE_ESTADO	MORENA	PT_MORENA
1	'010000M0100'	AGUASCALIENTES	378.00	
2	'010338B0100'	AGUASCALIENTES	153.00	
3	'010338C0100'	AGUASCALIENTES	159.00	
4	'010338C0200'	AGUASCALIENTES	136.00	
5	'010339B0100'	AGUASCALIENTES	151.00	
6	'010339C0100'	AGUASCALIENTES	132.00	

Concatenar verbos

- Podemos concatenar funciones de dplyr añadiendo pipas.
- Por ejemplo, podemos hacer lo mismo que anteriormente, pero en un solo paso.

```
presidencial<-presidencial %>%
  rename(votos=TOTAL_VOTOS_CALCULADOS,
         lista_nominal=LISTA_NOMINAL_CASILLA) %>%
  mutate(participacion=votos/
           lista_nominal) %>%
  select(CLAVE_CASILLA, NOMBRE_ESTADO,
         contains('MORENA'))
```

Otros verbos

Algunas otras funciones notables son

- **sample_n()** para seleccionar n observaciones aleatoriamente
- **sample_frac()** para seleccionar un porcentaje de observaciones aleatoriamente.
- **replace_na()** para reemplazar NA's

Section 5

Agrupar datos

group_by()

A veces las observaciones pertenecen a una o más categorías.

- Por ejemplo, los datos panel están agrupados por entidad y por tiempo.

R puede agrupar fácilmente con group_by()

- Después de agrupar podemos añadir variables o comprimir bases de datos.
- Podemos agrupar por más de una categoría separando por una coma.

Por ejemplo, agrupemos por estado y añadamos el promedio de votos por morena por estado

```
presidencial<- presidencial %>%
  group_by(NOMBRE_ESTADO) %>%
  mutate(
   voto_morena= mean(MORENA, na.rm=T)
  )
```

	voto_morena	CLAVE_CASILLA	CLAVE_ACTA	ID_ESTADO	N
1	111.28	'010000M0100'	010000M010001	1.00	A
2	111.28	'010338B0100'	010338B010002	1.00	A
3	111.28	'010338C0100'	010338C010002	1.00	A
4	111.28	'010338C0200'	010338C020002	1.00	A
5	111.28	'010339B0100'	010339B010002	1.00	A
6	111.28	'010339C0100'	010339C010002	1.00	A

na.rm=T

- Los NA son contagiosos: casi todo lo que hagamos dará NA
- Filter no incluye los NA en la condición, así que hay que unir con | is.na()
- ¿Cómo manejamos los NA?
- Hay funciones que ignoran los NA
- Generalmente el argumento que incertamos es **na.rm=T**

summarise()

- Usamos summarise() si queremos comprimir la base de datos.
- La base de datos se modifica totalmente
- Las nuevas observaciones pasan a ser el/los argumento(s) por los que agrupamos.
- Solo tendremos las variables que especifiquemos dentro del summarise()

Auxiliares summarise()

- **across()** sirve para hacer la misma operación con varias variables con mutate() o summarise()
- Al meter las columnas podemos usar la sintaxis y auxiliares que usaríamos con select(): begins_with(), contains(), everything(), etc.
- **c_across()** indica que queremos hacer una operación utilizando varias variables
- n() sirve para añadir cuantas observaciones hay dentro de cada grupo

Ejemplo summarise() y across()

- Agrupemos por Estado y saquemos los votos totales por partido por estado

```
prom_estados<- presidencial %>%
  group_by(NOMBRE_ESTADO) %>%
  summarise(
      across(PAN:CAND_IND_02, sum)
  )
```

- Sin el across tendríamos que hacer summarise(pan=pan, prd=prd, etc)

	NOMBRE_ESTADO	PAN	PRI	PRD	PVE
1	AGUASCALIENTES	162349.00	88820.00	7442.00	6216.0
2	BAJA CALIFORNIA	239038.00	102272.00	13090.00	8873.0
3	BAJA CALIFORNIA SUR	51812.00	21631.00	1409.00	2797.0
4	CAMPECHE	43742.00	82300.00	4945.00	2950.0
5	CHIAPAS				
6	CHIHUAHUA				

row_wise()

- Hasta ahora, utilizamos mutate o summarise calculamos la operación a lo largo de la columna (la variable)
- El summarise() anterior es un claro ejemplo. Vimos al interior del Estado y sumamos los votos a lo largo de la columna

- **rowwise()** es un verbo que nos ayuda a hacer operaciones a lo largo de las filas.
- Si añadimos rowwise() le indicamos a dplyr que las operaciones las queremos a lo largo de la fila
- En nuestro ejemplo, sería muy útil para sumar los votos de las coaliciones

Ejemmplo rowwise()

- Calculemos el total de los votos obtenidos por MORENA

```
presidencial<- presidencial %>%
  rowwise() %>%
  mutate(
    total_morena= sum(c_across(contains('MORENA')))- voto_more
    )
```

- Restamos voto_morena porque también lo incluiría y es un estadístico que sacamos

	CLAVE_CASILLA	total_morena	CLAVE_ACTA	ID_ESTADO	I
1	'010000M0100'	433.00	010000M010001	1.00	A
2	'010338B0100'	160.00	010338B010002	1.00	A
3	'010338C0100'	162.00	010338C010002	1.00	A
4	'010338C0200'	143.00	010338C020002	1.00	A
5	'010339B0100'	154.00	010339B010002	1.00	A
6	'010339C0100'	136.00	010339C010002	1.00	A

across() vs c_across()

- Si queremos añadir múltiples columnas con, por ejemplo, el promedio de cada una de las variables, lo podemos hacer con across()
- Si queremos hacer operaciones cuyo output sea una sola variables, pero que necesite de input múltiples variables utilizamos c_across

Section 6

Otras funciones

Menciono otras funciones interesantes que pueden llegar a ser útiles al manejar datos y en conjunto con dplyr

case_when()

- Hay veces que queremos hacer un ifelse con varias condiciones
- concatenar un ifelse() se vuelve progresivamente difícil

case_when(condicion_1 ~ qué pone R si se cumple,

condicion_2 ~ ” “,

...

TRUE ~ qué pone R e.o.c.)

Ejemplo case_when()

- Creemos una variable que dependa de los valores que pueda tomar la participación que se llame participativo
  - Si es menor a 30%, que valga “baja”
  - Entre 30 y 60 que sea “promedio”
  - Mayor a 60 que diga “muy”

```
presidencial<- presidencial %>%
  mutate(
    participativo=case_when(
      participacion<0.30 ~ 'poco',
      participacion>0.30 & participacion<=0.60 ~ 'promedio',
      participacion>0.60 ~ 'muy'
    )
  )
```

	CLAVE_CASILLA	participativo	CLAVE_ACTA	ID_ESTADO	N
1	'010000M0100'	promedio	010000M010001	1.00	A
2	'010338B0100'	promedio	010338B010002	1.00	A
3	'010338C0100'	promedio	010338C010002	1.00	A
4	'010338C0200'	promedio	010338C020002	1.00	A
5	'010339B0100'	promedio	010339B010002	1.00	A
6	'010339C0100'	promedio	010339C010002	1.00	A

recode()

- Hay veces que queremos cambiar el nombre de los factores en un df
- **recode()** preserva las categorizaciones, pero alterando los nombres de los factores.

factor()

- Podemos fácilmente convertir una variable caracter o numérica en factor con **factor()**
- Hay veces que queremos que sea un factor y no solo texto, especialmente cuando grafiquemos.

Section 7

Merges y cambio de estructura

Merges

Hay veces que queremos juntas bases de datos con las mismas observaciones.

- Por ejemplo, nuestra base de ministros con datos del PIB.
- Hay muchos tipos de merges y una familia de funciones para todos los casos
- Evidentemente, las categorías deseadas tienen que estar **escritas idénticamente**.

tipo_join(x,y,

by=c('variable1.x'='variable1.y',

'variable2.x'='variable2.y'))

Tipos de merge

- **left_join()** A la base de la izquierda le añade lo de la derecha. Observaciones solo en la base derecha se pierden.
- **right_join()**
- **inner_join()** la intersección de las bases de datos
- **full_join()** la unión

Cambio de estructura

Habrá veces que queremos cambiar la estructura de los datos. Pensemos en nuestro ejemplo. Cada partido es una variable, sin embargo, todos pertenecen a una misma categoría: partidos.

- Si pudiéramos cambiar la estructura de datos de casilla a casilla-partido podríamos, por ejemplo, agrupar por la variable partido

pivot_longer()

- pivot_longer() transforma la estructura de los datos
- Hace exactamente lo antes mencionado: pasa de un formato *wide* a uno *long*
- Veamos cómo pasar todos los partidos a una sola variable, cambiando la unidad de observación de casilla a casilla-partido

```
presidencial_long<- presidencial %>%
  pivot_longer(PAN:CAND_IND_02,
               names_to = 'partido',
               values_to = 'votos_partido') %>%
  select(CLAVE_CASILLA, partido, votos_partido, everything())
```

	CLAVE_CASILLA	partido	votos_partido	CL
1	'010000M0100'	PAN	247.00	01
2	'010000M0100'	PRI	37.00	01
3	'010000M0100'	PRD	8.00	01
4	'010000M0100'	PVEM	1.00	01
5	'010000M0100'	PT	24.00	01
6	'010000M0100'	MOVIMIENTO CIUDADANO	4.00	01

- pivot_longer() es un verbo de dplyr
- el primer argumento son las variables que queremos convertir
  - acepta la sintaxis de select()
- el segundo argumento es el nombre de la columna en la que va a colapsar las variables anteriores
  - i.e. que categoría comparten esas variables
- El segundo argumento es cómo se va a llamar la columna en la que va a poner los valores

Así, de tener una df con una columna para cada partido y los votos como valores a lo largo de todas esas variables, terminamos con un df con una variable de partido y otra de los votos por ese partido, pero con muhcas más observacion. Lo que sucede es que se alteró la unidad de observación: de casilla a casilla-partido.

pivot_wider()

- Evidentemente, hay un verbo que hace lo contrario, que pasa de un formato long a uno wide
- Sirve para dividir categorías en múltiples columnas

```
presidencial_wide<- presidencial_long %>%
  pivot_wider(names_from = partido,
              values_from = votos_partido)
```

- Evidentemente, queda como nuestro df original
- Podemos descomponer varias categorías en múltiples variables si añadimos las variables como vector a values_from=
- Si quisiéramos hacer una variable por partido-estado

```
presidencial_wide<- presidencial_long %>%
  pivot_wider(names_from = partido,
              values_from = c(votos_partido, NOMBRE_ESTADO))
```

arrange()

- arrange() es un verbo que sirve para acomodar las observaciones en orden ascendente o descendente de acuerdo con un criterio (variable)

arrange(variable que contienen letras o números)

- Por default lo hace en orden ascendente
  - Si queremos descendiente, tenemos que encerrar la columna entre **desc()**
- Podemos especificar si queremos ordenar al interior de cada grupo con el argumento .by_group=T

Auxiliares arrange()

- Podemos aprovechar que los datos ya estén en orden
- first() toma la primera observación
- last()
- nth(x, número)
  - Si queremos el segundo: nth(vector, 2)
- lag() recrea el vector pero con un rezago
- lead() recrea el vector pero un periodo adelantado

Ejemplo arrange()

- Creemos una variable que identifique el ganador para cada casilla

```
presidencial_long <- presidencial_long %>%
  group_by(CLAVE_CASILLA) %>%
  arrange(desc(votos_partido), .by_group = T) %>%
  mutate(ranking=row_number(),
         ganador=first(partido))
```

- Además añadimos el ranking de cada partido con row_number

	CLAVE_CASILLA	partido	ranking	ganador
1	'010000M0100'	MORENA	1	MORENA
2	'010000M0100'	PAN	2	MORENA
3	'010000M0100'	PT_MORENA_PES	3	MORENA
4	'010000M0100'	PRI	4	MORENA
5	'010000M0100'	PAN_PRD_MC	5	MORENA
6	'010000M0100'	CAND_IND_02	6	MORENA